

ДЗ

Анализ характера влияния возраста на дефолт по кредиту с использованием KAN

Студент группы ИУ6-13М
Петров В.Д.

Декабрь 2025

Содержание

1	Введение	2
1.1	Гипотеза исследования	2
1.2	Цели и задачи	2
2	Теоретическая основа	2
3	Подготовка данных	2
4	Предварительный анализ данных	3
5	Построение модели	3
6	Представление результатов	4

1 Введение

1.1 Гипотеза исследования

С помощью нейронных сетей Колмогорова-Арнольда возможно построить прозрачную модель для анализа влияния определённых параметров и связей. В данном проекте рассматривается анализ влияния возраста на вероятность дефолта по кредиту. Гипотеза по данным - зависимость будет квадратичной. Гипотеза по методу - возможно будет построить точную и прозрачную нейронную сеть.

1.2 Цели и задачи

- Найти данные для анализа
- Подготовить и обработать данные для последующей тренировки модели KAN
- Провести предварительный анализ данных
- Реализовать прототип модели на основе архитектуры KAN
- Провести эксперименты на тестовой выборке
- Визуализировать результаты работы модели

2 Теоретическая основа

Сети Колмогорова-Арнольда (KAN) - это новая архитектура нейронных сетей, основанная на теореме представления Колмогорова-Арнольда. В отличие от классических многослойных перцептронов (MLP), KAN заменяют линейные веса на обучаемые универсальные функции на рёбрах сети, что обеспечивает большую точность, лучшую интерпретируемость и более высокую эффективность в задачах аппроксимации функций и решения дифференциальных уравнений.

Теорема Колмогорова-Арнольда утверждает, что любую непрерывную функцию от нескольких переменных можно точно представить в виде конечной суперпозиции непрерывных функций одной переменной и операции сложения.

3 Подготовка данных

В качестве датасета выбраны данные соревнования Home Credit Default Risk. Размер обучающей выборки составляет 307511 записей. В представленном датасете присутствуют 122 различных признака, имеющих сложную структуру в разных таблицах. В качестве целевого параметра будет служить показатель `target`, указывающий на возникшие трудности с возвращением кредита.

Чтобы не загружать признаками небольшую модель, были выбраны 9 ключевых признаков: возраст, общий доход, сумма кредита, сумма аннуитета, стаж работы и 3 внешних кредитных рейтинга.

Затем были удалены все лишние столбцы, а также записи с пустыми полями, которых в представленном датасете было больше половины. В результате осталось 109582 записи. После чего 20 процентов данных было отделено для дальнейшей проверки модели. Таким образом, итоговый тренировочный датасет составил 87650 записей.

4 Предварительный анализ данных

В первую очередь было проверено распределение целевой переменной.

Распределение целевой переменной:

TARGET

0 0.927014

1 0.072986

Можно заметить, что наблюдается дисбаланс классов. 93 процента людей не имеют проблем при возвращении кредита. Данную проблему можно решить с использованием SMOTE, повысив или понизив размерность данных.

После было проанализировано

Корреляция признаков:

EXT_SOURCE_3 -0.173472

EXT_SOURCE_1 -0.154757

EXT_SOURCE_2 -0.144827

AGE -0.066010

AMT_CREDIT -0.029245

DAYS_EMPLOYED -0.027075

AMT_ANNUITY -0.009171

AMT_INCOME_TOTAL 0.004591

CNT_CHILDREN 0.009776

TARGET 1.000000

Таким образом, все данные слабо коррелируют с таргетом (кроме самого таргета, который, понятно, равен сам себе). Однако из данных выделяются возраст и внешние оценки кредитного риска.

Можно заметить, что количество записей убывает с возрастом, что может негативно сказаться на точности модели.

Далее были рассчитаны распределение ядерной плотности займов выплаченных вовремя и с опозданием.

Можно заметить, что распределение по возрасту довольно схоже.

Наконец были представлены графики для отображения возраста по группам дефолта, статистическая зависимость дефолта от возраста, от группы возрастов и корреляция с другими признаками.

Можно заметить некую коллинеарность возраста с внешним признаком, а также уменьшение вероятности дефолта с уменьшением возраста. Однако это можно списать на уменьшенное количество данных у людей в возрасте.

5 Построение модели

От использования SMOTE пришлось отказаться, так как добавление или уменьшение данных всегда приводило к значительным уменьшениям точности. Также были опробованы четырёхслойные и двухслойные модели. Они показали уменьшенную точность. В итоге финальная структура модели - 9 входных слоёв под признаки, 10 нейронов в первом скрытом слое, 5 нейронов во втором скрытом слое, один выходной нейрон. В качестве основных гиперпараметров - grid равен трём, k равен 3. На обучение отводится 150 шагов.

Внутренний граф показан на рисунке 4.




Рис. 1: Визуализация возрастов клиентов

6 Представление результатов

Ниже приведены полученные метрики точности для данной модели. Данный расклад лучший из найденных.

	precision	recall	f1-score	support
0	0.96	0.73	0.83	20317
1	0.16	0.65	0.26	1600
accuracy			0.72	21917
macro avg	0.56	0.69	0.54	21917
weighted avg	0.91	0.72	0.79	21917

ROC-AUC: 0.7499

Точность модели составляет 72-74 процентов, ROC-AUC = 75 процентов. Модель обладает значимой предсказательной силой, но дисбаланс классов портит общую картину.

Ниже приведены математические функции на каждом из ребёр. Малозначимые рёбра обнулены.

```
fixing (0,0,0) with 0, r2=0.0, c=0
fixing (0,0,1) with 0, r2=0.0, c=0
fixing (0,0,2) with 0, r2=0.0, c=0
fixing (0,0,3) with 0, r2=0.0, c=0
```




Рис. 2: Распределение ядерной плотности займов




Рис. 3: Аналитические графики




Рис. 4: Граф устройства модели

```
fixing (0,0,4) with 0, r2=0.0, c=0
fixing (0,0,5) with 0, r2=0.0, c=0
fixing (0,0,6) with 0, r2=0.0, c=0
fixing (0,0,7) with 0, r2=0.0, c=0
fixing (0,0,8) with 0, r2=0.0, c=0
fixing (0,0,9) with 0, r2=0.0, c=0
fixing (0,1,0) with 0, r2=0.0, c=0
fixing (0,1,1) with 0, r2=0.0, c=0
fixing (0,1,2) with 0, r2=0.0, c=0
fixing (0,1,3) with 0, r2=0.0, c=0
fixing (0,1,4) with 0, r2=0.0, c=0
fixing (0,1,5) with 0, r2=0.0, c=0
fixing (0,1,6) with 0, r2=0.0, c=0
fixing (0,1,7) with 0, r2=0.0, c=0
fixing (0,1,8) with 0, r2=0.0, c=0
fixing (0,1,9) with 0, r2=0.0, c=0
fixing (0,2,0) with 0, r2=0.0, c=0
fixing (0,2,1) with 0, r2=0.0, c=0
fixing (0,2,2) with 0, r2=0.0, c=0
fixing (0,2,3) with 0, r2=0.0, c=0
fixing (0,2,4) with 0, r2=0.0, c=0
fixing (0,2,5) with 0, r2=0.0, c=0
fixing (0,2,6) with 0, r2=0.0, c=0
fixing (0,2,7) with 0, r2=0.0, c=0
fixing (0,2,8) with 0, r2=0.0, c=0
fixing (0,2,9) with 0, r2=0.0, c=0
fixing (0,3,0) with 0, r2=0.0, c=0
fixing (0,3,1) with 0, r2=0.0, c=0
fixing (0,3,2) with 0, r2=0.0, c=0
fixing (0,3,3) with 0, r2=0.0, c=0
fixing (0,3,4) with 0, r2=0.0, c=0
fixing (0,3,5) with 0, r2=0.0, c=0
fixing (0,3,6) with 0, r2=0.0, c=0
fixing (0,3,7) with 0, r2=0.0, c=0
fixing (0,3,8) with 0, r2=0.0, c=0
fixing (0,3,9) with 0, r2=0.0, c=0
fixing (0,4,0) with 0, r2=0.0, c=0
fixing (0,4,1) with 0, r2=0.0, c=0
fixing (0,4,2) with 0, r2=0.0, c=0
fixing (0,4,3) with 0, r2=0.0, c=0
fixing (0,4,4) with 0, r2=0.0, c=0
fixing (0,4,5) with 0, r2=0.0, c=0
fixing (0,4,6) with 0, r2=0.0, c=0
fixing (0,4,7) with 0, r2=0.0, c=0
fixing (0,4,8) with 0, r2=0.0, c=0
fixing (0,4,9) with 0, r2=0.0, c=0
fixing (0,5,0) with x, r2=0.992481529712677, c=1
fixing (0,5,1) with 0, r2=0.0, c=0
fixing (0,5,2) with x^3, r2=1.0000003576278687, c=3
fixing (0,5,3) with 0, r2=0.0, c=0
```

fixing (0,5,4) with x, r2=0.9792362451553345, c=1
fixing (0,5,5) with tan, r2=0.9999132752418518, c=3
fixing (0,5,6) with 0, r2=0.0, c=0
fixing (0,5,7) with 0, r2=0.0, c=0
fixing (0,5,8) with 0, r2=0.0, c=0
fixing (0,5,9) with 0, r2=0.0, c=0
fixing (0,6,0) with x^2 , r2=0.9979065656661987, c=2
fixing (0,6,1) with 0, r2=0.0, c=0
fixing (0,6,2) with x, r2=0.9543364644050598, c=1
fixing (0,6,3) with 0, r2=0.0, c=0
fixing (0,6,4) with 0, r2=0.0, c=0
fixing (0,6,5) with 0, r2=0.0, c=0
fixing (0,6,6) with 0, r2=0.0, c=0
fixing (0,6,7) with 0, r2=0.0, c=0
fixing (0,6,8) with 0, r2=0.0, c=0
fixing (0,6,9) with 0, r2=0.0, c=0
fixing (0,7,0) with 0, r2=0.0, c=0
fixing (0,7,1) with 0, r2=0.0, c=0
fixing (0,7,2) with x, r2=0.9719037413597107, c=1
fixing (0,7,3) with 0, r2=0.0, c=0
fixing (0,7,4) with 0, r2=0.0, c=0
fixing (0,7,5) with 0, r2=0.0, c=0
fixing (0,7,6) with 0, r2=0.0, c=0
fixing (0,7,7) with 0, r2=0.0, c=0
fixing (0,7,8) with 0, r2=0.0, c=0
fixing (0,7,9) with 0, r2=0.0, c=0
fixing (0,8,0) with 0, r2=0.0, c=0
fixing (0,8,1) with 0, r2=0.0, c=0
fixing (0,8,2) with x, r2=0.9648628830909729, c=1
fixing (0,8,3) with 0, r2=0.0, c=0
fixing (0,8,4) with 0, r2=0.0, c=0
fixing (0,8,5) with 0, r2=0.0, c=0
fixing (0,8,6) with 0, r2=0.0, c=0
fixing (0,8,7) with 0, r2=0.0, c=0
fixing (0,8,8) with 0, r2=0.0, c=0
fixing (0,8,9) with 0, r2=0.0, c=0
fixing (1,0,0) with 0, r2=0.0, c=0
fixing (1,0,1) with 0, r2=0.0, c=0
fixing (1,0,2) with 0, r2=0.0, c=0
fixing (1,0,3) with 0, r2=0.0, c=0
fixing (1,0,4) with 0, r2=0.0, c=0
fixing (1,1,0) with 0, r2=0.0, c=0
fixing (1,1,1) with 0, r2=0.0, c=0
fixing (1,1,2) with 0, r2=0.0, c=0
fixing (1,1,3) with 0, r2=0.0, c=0
fixing (1,1,4) with 0, r2=0.0, c=0
fixing (1,2,0) with 0, r2=0.0, c=0
fixing (1,2,1) with 0, r2=0.0, c=0
fixing (1,2,2) with 0, r2=0.0, c=0
fixing (1,2,3) with 0, r2=0.0, c=0

```

fixing (1,2,4) with 0, r2=0.0, c=0
fixing (1,3,0) with 0, r2=0.0, c=0
fixing (1,3,1) with 0, r2=0.0, c=0
fixing (1,3,2) with 0, r2=0.0, c=0
fixing (1,3,3) with 0, r2=0.0, c=0
fixing (1,3,4) with 0, r2=0.0, c=0
fixing (1,4,0) with 0, r2=0.0, c=0
fixing (1,4,1) with 0, r2=0.0, c=0
fixing (1,4,2) with 0, r2=0.0, c=0
fixing (1,4,3) with 0, r2=0.0, c=0
fixing (1,4,4) with 0, r2=0.0, c=0
fixing (1,5,0) with 0, r2=0.0, c=0
fixing (1,5,1) with 0, r2=0.0, c=0
fixing (1,5,2) with 0, r2=0.0, c=0
fixing (1,5,3) with 0, r2=0.0, c=0
fixing (1,5,4) with 0, r2=0.0, c=0
fixing (1,6,0) with 0, r2=0.0, c=0
fixing (1,6,1) with 0, r2=0.0, c=0
fixing (1,6,2) with 0, r2=0.0, c=0
fixing (1,6,3) with 0, r2=0.0, c=0
fixing (1,6,4) with 0, r2=0.0, c=0
fixing (1,7,0) with 0, r2=0.0, c=0
fixing (1,7,1) with 0, r2=0.0, c=0
fixing (1,7,2) with 0, r2=0.0, c=0
fixing (1,7,3) with 0, r2=0.0, c=0
fixing (1,7,4) with 0, r2=0.0, c=0
fixing (1,8,0) with 0, r2=0.0, c=0
fixing (1,8,1) with 0, r2=0.0, c=0
fixing (1,8,2) with 0, r2=0.0, c=0
fixing (1,8,3) with 0, r2=0.0, c=0
fixing (1,8,4) with 0, r2=0.0, c=0
fixing (1,9,0) with 0, r2=0.0, c=0
fixing (1,9,1) with 0, r2=0.0, c=0
fixing (1,9,2) with 0, r2=0.0, c=0
fixing (1,9,3) with 0, r2=0.0, c=0
fixing (1,9,4) with 0, r2=0.0, c=0
fixing (2,0,0) with 1/x^2, r2=0.9994083642959595, c=2
fixing (2,1,0) with 0, r2=0.0, c=0
fixing (2,2,0) with 1/x^2, r2=0.9973751306533813, c=2
fixing (2,3,0) with 1/x^2, r2=0.9999749064445496, c=2
fixing (2,4,0) with 1/x^2, r2=0.9996364116668701, c=2

```

На рисунке 5 можно наблюдать результат воссоздания функции влияния возраста на вероятность дефолта по кредиту. Можно заметить, что итоговая зависимость почти незначительна, за исключением аномалии с повышением возраста. График чувствительности подтверждает слабую корреляцию.

На рисунке 6 продемонстрирована относительная важность признаков внутри модели. Возраст отвечает за 6 процентов отклонений, когда как подавляющая часть влияния на результат исходит от внешних кредитных оценок.




Рис. 5: Зависимость вероятности дефолта от возраста




Рис. 6: Относительная важность признаков

Заключение

В результате работы была построена модель, которая с неплохой точностью способна предсказывать возможные проблемы с кредитом у клиентов. Гипотеза про параболическую зависимость не подтвердилась, зависимость от возраста незначительная. Гипотеза по методу подтвердилась - была построена точная и прозрачная нейронная сеть.

Список литературы

[1] Курс лекций